

# Transformers and LLMs as the New Benchmark in Early Cancer Detection

Yulia Kumar<sup>1</sup> , Kuan Huang<sup>1</sup> , Zachary Gordon<sup>1</sup> , Lais Castro<sup>1</sup> , Egan Okumu<sup>1</sup> , Patricia Morreale<sup>1</sup> and J. Jenny Li<sup>1</sup>

# Introdução: Desafio Clínico e Inovação

A Leucemia Linfoblástica Aguda (ALL) é um câncer agressivo que afeta principalmente pessoas jovens. Os métodos tradicionais são invasivos e demorados, então há uma necessidade urgente por soluções mais rápidas e acessíveis. Com isso, modelos de Inteligência Artificial, especialmente Transformers, vêm sendo aplicados para tentar superar esses desafios

# Objetivos do Estudo

Os objetivos principais do estudo foram:


- Comparar o desempenho dos transformers com CNNs na detecção precoce de ALL.
- Avaliar como LLMs podem apoiar pacientes e profissionais.
- Identificar e mitigar vieses em modelos de IA.

# Dataset Utilizado

O dataset usado foi retirado do Kaggle, com 3.256 imagens de esfregaços sanguíneos, divididas em quatro classes: Benigno, Early, Pre-B e Pro-B. Isso possibilitou testar a robustez dos modelos sem a necessidade de segmentação manual das imagens.

**Table 1.** The project dataset.

Types of ALL	The # of images	Comments
Benign	504	Noncancerous
Early	985	Early-stage type (L1)
Pre	963	Middle stage type (L2)
Pro	804	Later stage type (L3)
Classification	4 classes	Benign, Early, Pre, Pro



**Fig. 1.** The project ALL dataset (top: original benign, early, pre, pro images; bottom: corresponding segmented images).

# Arquitetura dos Transformers

**DAT:** utiliza atenção deformável para focar em partes relevantes da imagem.

**Swin Transformer:** introduz uma hierarquia e desloca as janelas de atenção, o que melhora o desempenho em imagens grandes.

Isso permite que os transformers superem dificuldades de segmentação e captem padrões complexos dos dados médicos.

# Metodologia e Configuração Experimental

Os modelos foram treinados em 80% dos dados, testados nos 20% restantes, com batch size de 16, imagens redimensionadas para 256x256 e otimizador SGD.

**Table 3.** Experimental Parameters.

Parameter	Comment
Initial Dataset	3256 images
Class	80% for training, 20% for testing at random
Batch Size	4 classes (Benign, Early, Pre, Pro)
Input Image	16
Optimizer	256×256 (resized)
# of Epochs	SGD, learning rate 0.001.
PyTorch	300
Hardware	1.12.1.
	Ubuntu 20.04.5 Linux system : AMD EPYC 7513 32-Core Processor 2.60GHz, 8 NVIDIA GeForce 3090 graphics cards, each one of 24 Gb

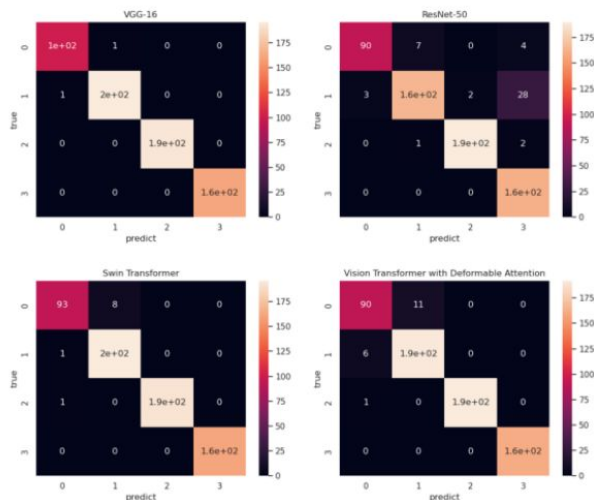
# Resultados: Desempenho dos Modelos

Os resultados mostram que os transformers DAT e Swin superaram o ResNet-50 em praticamente todas as classes, atingindo até 97,7% de acurácia com o Swin. A VGG-16 teve excelente performance, mas os transformers se destacam pela capacidade de análise sem segmentação.

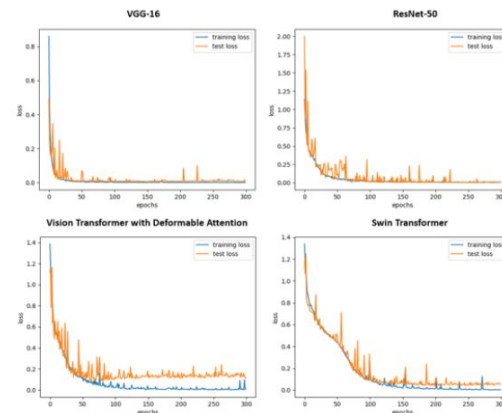
**Table 2.** Comparative Results of various models.

Model	Accuracy, %				
	Benign	Early	Pre	Pro	Average
ResNet-50	89.11	83.25	98.45	100	92.7025
VGG-16	99.01	99.49	100	100	99.6250
DAT	89.11	96.95	99.48	100	96.3850
Swin	92.08	99.49	99.48	100	97.7625

# Resultados: Desempenho dos Modelos



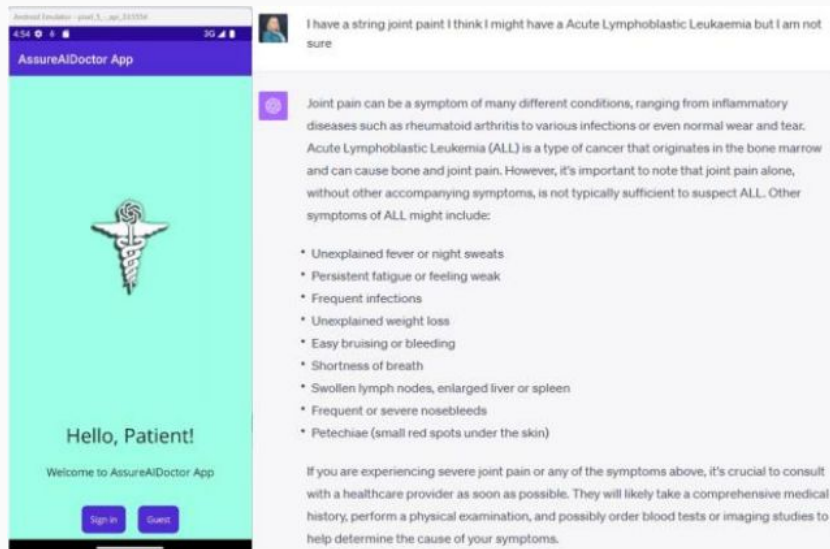
**Fig. 3.** Confusion Matrices for VGG-16 (top left), ResNet-50 (top right), Swin (left bottom) and DAT (right bottom).



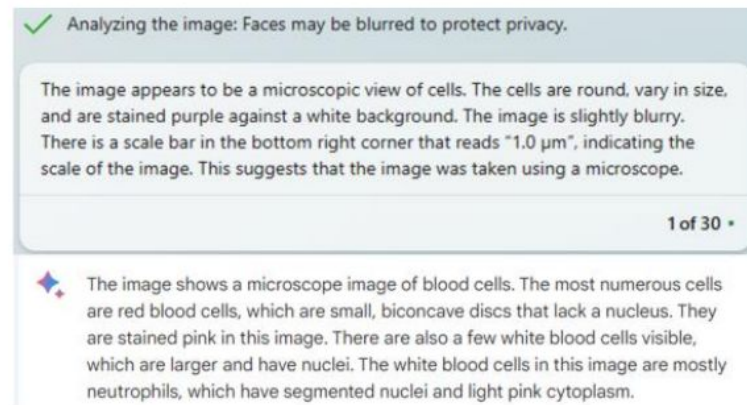
**Fig. 4.** Loss Curves for VGG-16, ResNet-50, DAT, and Swin.



# LLMs como Assistentes em Saúde

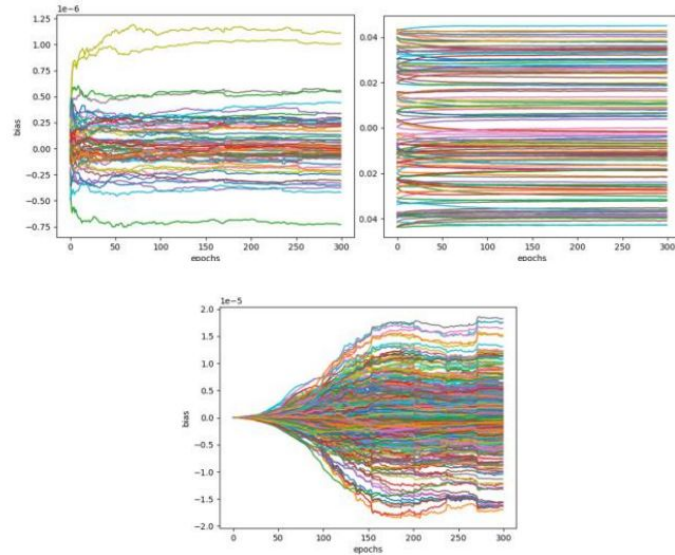


**Fig. 5.** The AssureAIDoctor's AI assistant for ALL patients.




**Fig. 6.** Bing (top) and Bard (bottom) Responses.

# Detecção e Análise de Viés



**Fig. 8.** Bias Visualizations of VGG-16 (the first convolutional layer), and DAT and Swin Models (MLP of Second Transformer Stage).



**Fig. 9.** CAM Results of DL Models.

# Conclusões e Perspectivas Futuras

Os transformers mostram-se altamente promissores para a detecção precoce de câncer, enquanto LLMs ampliam o suporte ao paciente. O principal desafio é garantir modelos robustos e livres de viés. O futuro aponta para diagnósticos mais precisos, acessíveis e humanizados, com IA cada vez mais integrada ao cuidado em saúde.